TD sur les données Visa Premier

Julien JACQUES

01/10/2024

Pré-traitements sur les données

Commençons par importer les données

```
data=read.table("VisaPremier.txt",header=TRUE,na.strings =".",stringsAsFactors = TRUE)
```

Identifions les variables catégorielles et quantitatives, puis créons deux jeux de données, quali. et quanti.

```
ind_categ_feature=c(1,2,3,4,6,8,9,45,46,47)
data_categ=data[,ind_categ_feature]
data_continuous=data[,-ind_categ_feature]
```

Commençons par regarder les variables catégorielles

```
summary(data_categ)
```

```
##     matricul          departem        ptvente        sexe     sitfamil
##  Min.   : 113333   Min.   : 6.00   Min.   :1.000   Sfem:405   F.  : 32
##  1st Qu.: 860436   1st Qu.:31.00   1st Qu.:1.000   Shom:668   Fcel:360
##  Median :1948586   Median :31.00   Median :1.000              Fdiv: 86
##  Mean   :2489307   Mean   :41.18   Mean   :1.664              Fmar:547
##  3rd Qu.:3901594   3rd Qu.:61.25   3rd Qu.:2.000              Fsep: 14
##  Max.   :7589439   Max.   :97.00   Max.   :7.000              Fuli: 25
##                    NA's   :7                                  Fveu:  9
##       csp       codeqlt    cartevp        sexer           cartevpr
##  Pcad   :446   A   :207   Cnon:714   Min.   :0.0000   Min.   :0.0000
##  Pemp   :288   B   :303   Coui:359   1st Qu.:0.0000   1st Qu.:0.0000
##  Psan   :199   C   :218              Median :0.0000   Median :0.0000
##  Pouv   : 85   D   :168              Mean   :0.3774   Mean   :0.3346
##  Part   : 31   E   : 44              3rd Qu.:1.0000   3rd Qu.:1.0000
##  Pret   : 21   NA's:133              Max.   :1.0000   Max.   :1.0000
##  (Other):  3
```

On peut voir qu'il y a des données manquantes, et certaines sont enregistrées comme des variables quantitative (integer)

On va remplacer les départements manquants par le département le plus fréquent. Pour trouver ce dernier ce n'est pas si simple. On va calculer un tableau de contigence que l'on va trier par ordre déceroissant. Le département le plus fréquent arrive en premier et on peut l'utiliser pour remplacer les données manquantes.

```
tmp=sort(table(data_categ$departem),decreasing=TRUE)
data_categ$departem[is.na(data_categ$departem)]=as.integer(names(tmp)[1])
data_categ$departem=factor(data_categ$departem)
```

Pour la variable codeqlt, comme il y a plus de NA, on va remplacer en tirant aléatoirement le codeqlt en fonction des fréquences observées chez les non NA

```
data_categ$codeqlt=as.factor(data_categ$codeqlt)
nbNA=length(data_categ$codeqlt[is.na(data_categ$codeqlt)])
data_categ$codeqlt[is.na(data_categ$codeqlt)]=sample(levels(data_categ$codeqlt),nbNA,
                                prob=table(data_categ$codeqlt),replace=TRUE)
data_categ$codeqlt=as.factor(data_categ$codeqlt)
```

Et on transforme les variables matricul et ptvente en variables catégorielles (factor)

```
data_categ$matricul=factor(data_categ$matricul)
data_categ$ptvente=factor(data_categ$ptvente)
```

On a deux variables redondantes qui sont le recodage de la variable sexe et de la variable possession de la carte Visa Premier. Je les supprime. Je supprime également le matricule du client dont je n'ai pas besoin ici

```
data_categ$sexer=NULL
data_categ$cartevpr=NULL
data_categ$matricul=NULL
```

On va maintenant remplacer automatiquement les NA des variables manquantes par la moyenne

```
summary(data_continuous)
```

```
##       age           anciente        nbimpaye    mtrejet
##  Min.   :18.00   Min.   :  1.0   Min.   :0   Min.   :-51.00000
##  1st Qu.:33.00   1st Qu.: 45.0   1st Qu.:0   1st Qu.:  0.00000
##  Median :43.00   Median :136.0   Median :0   Median :  0.00000
##  Mean   :42.53   Mean   :157.1   Mean   :0   Mean   : -0.07269
##  3rd Qu.:52.00   3rd Qu.:216.0   3rd Qu.:0   3rd Qu.:  0.00000
##  Max.   :65.00   Max.   :870.0   Max.   :0   Max.   :  0.00000
##
##     nbopguic         moycred3          aveparmo         endette
##  Min.   : 0.000   Min.   :    0.00   Min.   :     0   Min.   : 0.000
##  1st Qu.: 0.000   1st Qu.:    3.00   1st Qu.:     0   1st Qu.: 0.000
##  Median : 1.000   Median :   12.00   Median :  6017   Median : 0.000
##  Mean   : 1.505   Mean   :   47.63   Mean   : 57249   Mean   : 5.457
##  3rd Qu.: 2.000   3rd Qu.:   27.00   3rd Qu.: 57818   3rd Qu.: 6.000
##  Max.   :28.000   Max.   :19579.00   Max.   :970000   Max.   :99.000
##
##     engagemt          engagemc         engagemm          nbcptvue
##  Min.   :      0   Min.   :     0   Min.   :      0   Min.   :0.000
##  1st Qu.:      0   1st Qu.:     0   1st Qu.:      0   1st Qu.:1.000
##  Median :      0   Median :     0   Median :      0   Median :1.000
##  Mean   :  77316   Mean   :  4199   Mean   :  20230   Mean   :1.028
##  3rd Qu.:  34927   3rd Qu.:     0   3rd Qu.:      0   3rd Qu.:1.000
##  Max.   :3472938   Max.   :500780   Max.   :1618242   Max.   :4.000
##
##     moysold3         moycredi          agemvt            nbop
##  Min.   :-70050   Min.   :   0.00   Min.   :  0.00   Min.   :  0
##  1st Qu.:   434   1st Qu.:   2.00   1st Qu.: 13.00   1st Qu.:  6
##  Median :  4371   Median :  11.00   Median : 13.00   Median : 25
##  Mean   : 10674   Mean   :  25.91   Mean   : 19.06   Mean   : 29
##  3rd Qu.: 11034   3rd Qu.:  24.00   3rd Qu.: 14.00   3rd Qu.: 43
##  Max.   :241827   Max.   :4079.00   Max.   :944.00   Max.   :262
##                                     NA's   :6
##     mtfactur          engageml          nbvie             mtvie
##  Min.   :      0   Min.   :      0   Min.   : 0.0000   Min.   :      0
```

```
##  1st Qu.:      0   1st Qu.:      0   1st Qu.: 0.0000   1st Qu.:      0
##  Median :      0   Median :      0   Median : 0.0000   Median :      0
##  Mean   :  23379   Mean   :  52888   Mean   : 0.2395   Mean   :  35915
##  3rd Qu.:   3500   3rd Qu.:      0   3rd Qu.: 0.0000   3rd Qu.:      0
##  Max.   :1331530   Max.   :3472938   Max.   :13.0000   Max.   :5449561
##
##     nbeparmo        mteparmo           nbeparlo         mteparlo
##  Min.   :0.000   Min.   :       0   Min.   :0.0000   Min.   :     0
##  1st Qu.:0.000   1st Qu.:       0   1st Qu.:0.0000   1st Qu.:     0
##  Median :1.000   Median :    6017   Median :0.0000   Median :     0
##  Mean   :1.473   Mean   :   75442   Mean   :0.6524   Mean   : 32184
##  3rd Qu.:2.000   3rd Qu.:   58390   3rd Qu.:1.0000   3rd Qu.: 23854
##  Max.   :9.000   Max.   :19508920   Max.   :4.0000   Max.   :579603
##
##     nblivret         mtlivret         nbeparlt          mteparlt
##  Min.   :0.0000   Min.   :     0   Min.   :0.00000   Min.   :     0
##  1st Qu.:0.0000   1st Qu.:     0   1st Qu.:0.00000   1st Qu.:     0
##  Median :1.0000   Median :   127   Median :0.00000   Median :     0
##  Mean   :0.7586   Mean   : 20740   Mean   :0.05871   Mean   :  4325
##  3rd Qu.:1.0000   3rd Qu.: 15544   3rd Qu.:0.00000   3rd Qu.:     0
##  Max.   :4.0000   Max.   :970000   Max.   :6.00000   Max.   :559559
##
##     nbeparte           mteparte            nbbon              mtbon
##  Min.   :0.000000   Min.   :    0.00   Min.   :0.000000   Min.   :       0
##  1st Qu.:0.000000   1st Qu.:    0.00   1st Qu.:0.000000   1st Qu.:       0
##  Median :0.000000   Median :    0.00   Median :0.000000   Median :       0
##  Mean   :0.002796   Mean   :   19.71   Mean   :0.000932   Mean   :   18173
##  3rd Qu.:0.000000   3rd Qu.:    0.00   3rd Qu.:0.000000   3rd Qu.:       0
##  Max.   :1.000000   Max.   :21149.00   Max.   :1.000000   Max.   :19500000
##
##     nbpaiecb         nbcb          nbcbptar         avtscpte
##  Min.   : 0.0   Min.   :0.00   Min.   :0.0000   Min.   :       0
##  1st Qu.: 0.0   1st Qu.:0.00   1st Qu.:0.0000   1st Qu.:    3184
##  Median : 9.0   Median :1.00   Median :0.0000   Median :   23993
##  Mean   :11.5   Mean   :1.07   Mean   :0.1361   Mean   :  146819
##  3rd Qu.:18.0   3rd Qu.:2.00   3rd Qu.:0.0000   3rd Qu.:  114807
##  Max.   :69.0   Max.   :5.00   Max.   :4.0000   Max.   :19856243
##  NA's   :278
##     aveparfi          nbjdebit
##  Min.   :      0   Min.   :  0.00
##  1st Qu.:      0   1st Qu.:  0.00
##  Median :      0   Median :  0.00
##  Mean   :  50727   Mean   : 12.08
##  3rd Qu.:    500   3rd Qu.: 10.00
##  Max.   :7066619   Max.   :134.00
##
```

```
for (j in 1:ncol(data_continuous)){
  if (sum(is.na(data_continuous[,j]))>0){
    indiceNA=which(is.na(data_continuous[,j]))
    data_continuous[indiceNA,j]=median(data_continuous[,j],na.rm=TRUE)
  }
}
summary(data_continuous)
```

```
##       age           anciente        nbimpaye    mtrejet
##  Min.   :18.00   Min.   :  1.0   Min.   :0   Min.   :-51.00000
##  1st Qu.:33.00   1st Qu.: 45.0   1st Qu.:0   1st Qu.:  0.00000
##  Median :43.00   Median :136.0   Median :0   Median :  0.00000
##  Mean   :42.53   Mean   :157.1   Mean   :0   Mean   : -0.07269
##  3rd Qu.:52.00   3rd Qu.:216.0   3rd Qu.:0   3rd Qu.:  0.00000
##  Max.   :65.00   Max.   :870.0   Max.   :0   Max.   :  0.00000
##     nbopguic         moycred3          aveparmo         endette
##  Min.   : 0.000   Min.   :    0.00   Min.   :     0   Min.   : 0.000
##  1st Qu.: 0.000   1st Qu.:    3.00   1st Qu.:     0   1st Qu.: 0.000
##  Median : 1.000   Median :   12.00   Median :  6017   Median : 0.000
##  Mean   : 1.505   Mean   :   47.63   Mean   : 57249   Mean   : 5.457
##  3rd Qu.: 2.000   3rd Qu.:   27.00   3rd Qu.: 57818   3rd Qu.: 6.000
##  Max.   :28.000   Max.   :19579.00   Max.   :970000   Max.   :99.000
##     engagemt          engagemc         engagemm          nbcptvue
##  Min.   :      0   Min.   :     0   Min.   :      0   Min.   :0.000
##  1st Qu.:      0   1st Qu.:     0   1st Qu.:      0   1st Qu.:1.000
##  Median :      0   Median :     0   Median :      0   Median :1.000
##  Mean   :  77316   Mean   :  4199   Mean   :  20230   Mean   :1.028
##  3rd Qu.:  34927   3rd Qu.:     0   3rd Qu.:      0   3rd Qu.:1.000
##  Max.   :3472938   Max.   :500780   Max.   :1618242   Max.   :4.000
##     moysold3         moycredi           agemvt            nbop
##  Min.   :-70050   Min.   :   0.00   Min.   :  0.00   Min.   :  0
##  1st Qu.:   434   1st Qu.:   2.00   1st Qu.: 13.00   1st Qu.:  6
##  Median :  4371   Median :  11.00   Median : 13.00   Median : 25
##  Mean   : 10674   Mean   :  25.91   Mean   : 19.03   Mean   : 29
##  3rd Qu.: 11034   3rd Qu.:  24.00   3rd Qu.: 14.00   3rd Qu.: 43
##  Max.   :241827   Max.   :4079.00   Max.   :944.00   Max.   :262
##     mtfactur          engageml           nbvie             mtvie
##  Min.   :      0   Min.   :      0   Min.   : 0.0000   Min.   :      0
##  1st Qu.:      0   1st Qu.:      0   1st Qu.: 0.0000   1st Qu.:      0
##  Median :      0   Median :      0   Median : 0.0000   Median :      0
##  Mean   :  23379   Mean   :  52888   Mean   : 0.2395   Mean   :  35915
##  3rd Qu.:   3500   3rd Qu.:      0   3rd Qu.: 0.0000   3rd Qu.:      0
##  Max.   :1331530   Max.   :3472938   Max.   :13.0000   Max.   :5449561
##     nbeparmo         mteparmo           nbeparlo         mteparlo
##  Min.   :0.000   Min.   :       0   Min.   :0.0000   Min.   :     0
##  1st Qu.:0.000   1st Qu.:       0   1st Qu.:0.0000   1st Qu.:     0
##  Median :1.000   Median :    6017   Median :0.0000   Median :     0
##  Mean   :1.473   Mean   :   75442   Mean   :0.6524   Mean   : 32184
##  3rd Qu.:2.000   3rd Qu.:   58390   3rd Qu.:1.0000   3rd Qu.: 23854
##  Max.   :9.000   Max.   :19508920   Max.   :4.0000   Max.   :579603
##     nblivret         mtlivret          nbeparlt          mteparlt
##  Min.   :0.0000   Min.   :     0   Min.   :0.00000   Min.   :     0
##  1st Qu.:0.0000   1st Qu.:     0   1st Qu.:0.00000   1st Qu.:     0
##  Median :1.0000   Median :   127   Median :0.00000   Median :     0
##  Mean   :0.7586   Mean   : 20740   Mean   :0.05871   Mean   :  4325
##  3rd Qu.:1.0000   3rd Qu.: 15544   3rd Qu.:0.00000   3rd Qu.:     0
##  Max.   :4.0000   Max.   :970000   Max.   :6.00000   Max.   :559559
##     nbeparte           mteparte            nbbon              mtbon
##  Min.   :0.000000   Min.   :    0.00   Min.   :0.000000   Min.   :       0
##  1st Qu.:0.000000   1st Qu.:    0.00   1st Qu.:0.000000   1st Qu.:       0
##  Median :0.000000   Median :    0.00   Median :0.000000   Median :       0
##  Mean   :0.002796   Mean   :   19.71   Mean   :0.000932   Mean   :   18173
```

```
##  3rd Qu.:0.000000   3rd Qu.:    0.00   3rd Qu.:0.000000   3rd Qu.:       0
##  Max.   :1.000000   Max.   :21149.00   Max.   :1.000000   Max.   :19500000
##     nbpaiecb          nbcb         nbcbptar         avtscpte
##  Min.   : 0.00   Min.   :0.00   Min.   :0.0000   Min.   :       0
##  1st Qu.: 3.00   1st Qu.:0.00   1st Qu.:0.0000   1st Qu.:    3184
##  Median : 9.00   Median :1.00   Median :0.0000   Median :   23993
##  Mean   :10.85   Mean   :1.07   Mean   :0.1361   Mean   :  146819
##  3rd Qu.:14.00   3rd Qu.:2.00   3rd Qu.:0.0000   3rd Qu.:  114807
##  Max.   :69.00   Max.   :5.00   Max.   :4.0000   Max.   :19856243
##     aveparfi          nbjdebit
##  Min.   :      0   Min.   :  0.00
##  1st Qu.:      0   1st Qu.:  0.00
##  Median :      0   Median :  0.00
##  Mean   :  50727   Mean   : 12.08
##  3rd Qu.:    500   3rd Qu.: 10.00
##  Max.   :7066619   Max.   :134.00
```

On enlève également la variable nbimpaye qui est constante

```
data_continuous$nbimpaye=NULL
```

Analyse en composantes principales

Maintenant que le jeu de données est "propre", on peut faire une ACP

```
library(FactoMineR)
res.pca <- PCA(data_continuous, graph = FALSE)
barplot(res.pca$eig[,2],main="Pourcentage de variance expliquée")
```

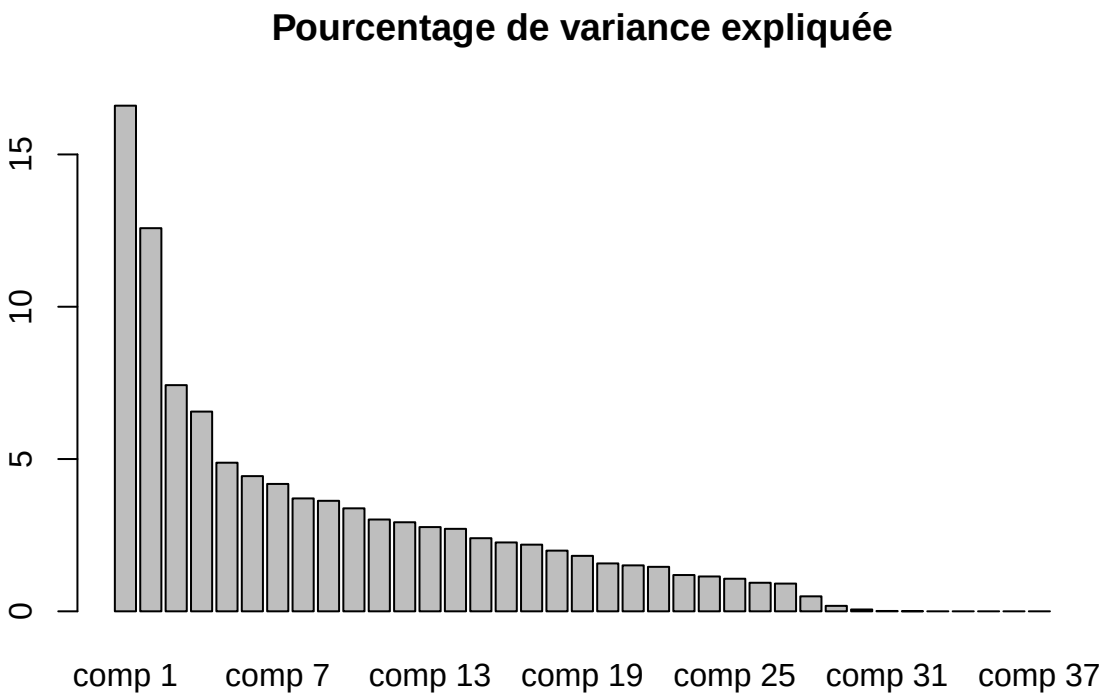


```
plot(res.pca,choix = "var")
```

```
## Warning: ggrepel: 24 unlabeled data points (too many overlaps). Consider
## increasing max.overlaps
```

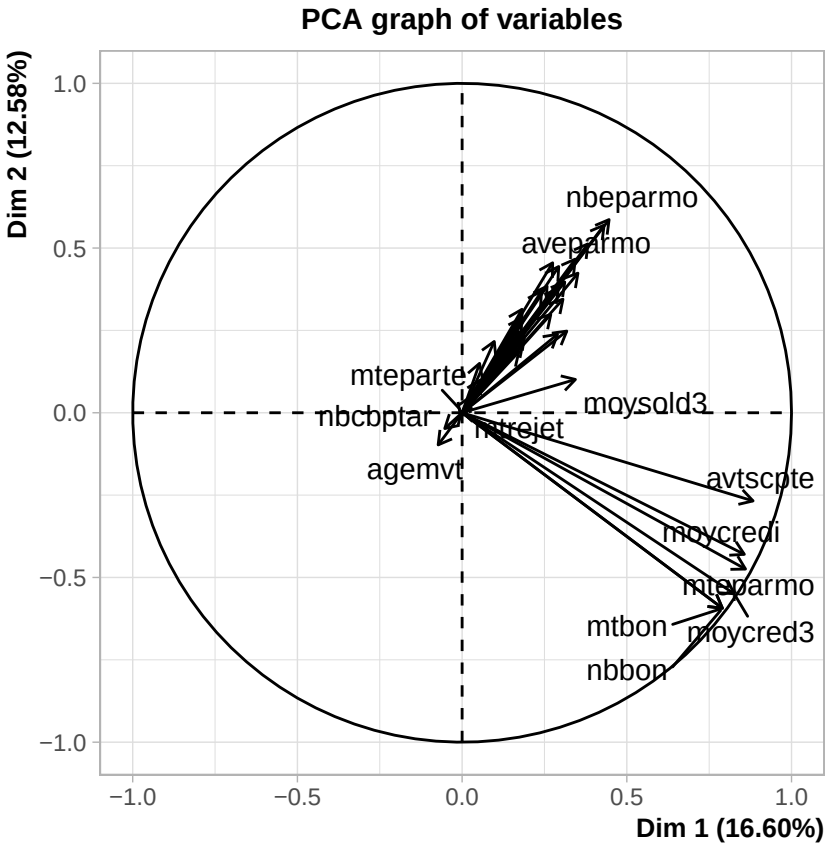


```
plot(res.pca,choix = "ind")
```

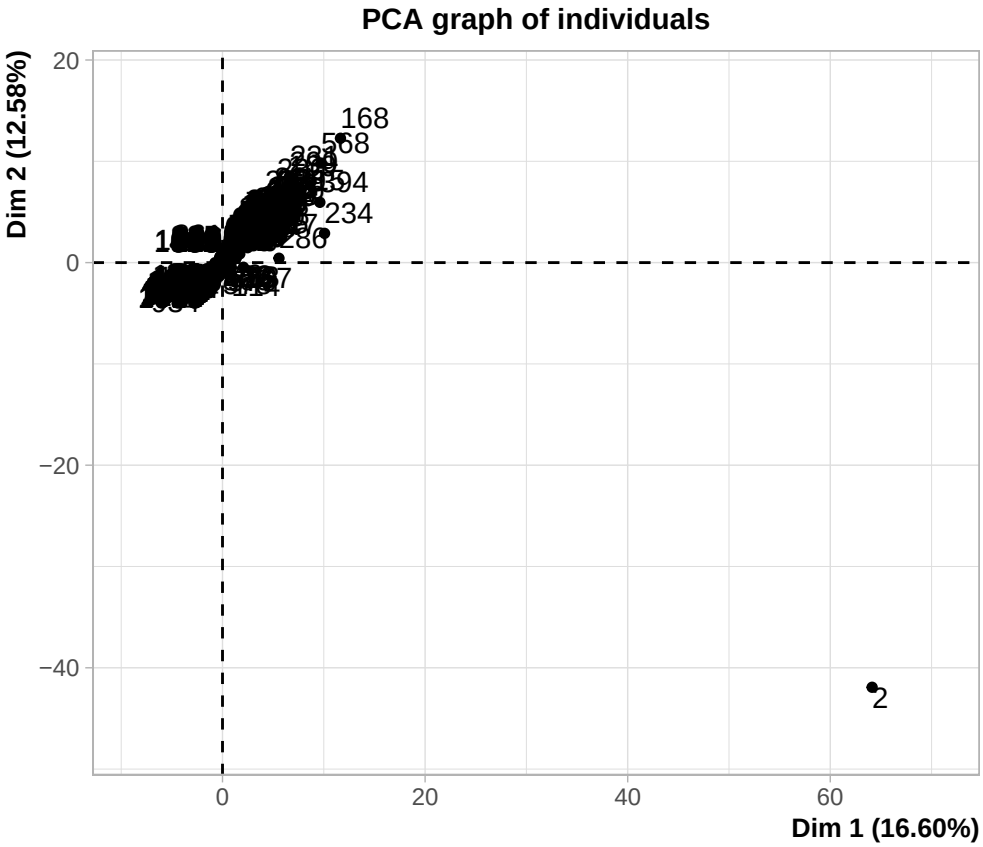

On remarque un individu (n°2) atypique. Après examen on remarque que c'est un individu très très riche, qui a des produits d'épargne dont il est le seul à en posséder parmi la base. Mettons cet individu de coté et offrons lui autant de carte VP qu'il veut.

```
data_continuous<-data_continuous[-2,]
data_categ<-data_categ[-2,]
```

Du coup on enlève les variables nbbon et mtbon qui deviennent constante une fois que l'on a enlevé cet individu

```
data_continuous$nbbon=NULL
data_continuous$mtbon=NULL
```

On peut recommencer l'ACP (qui a bien changé sans cet individu)

```
library(FactoMineR)
res.pca <- PCA(data_continuous, graph = FALSE)
barplot(res.pca$eig[,2],main="Pourcentage de variance expliquée")
```

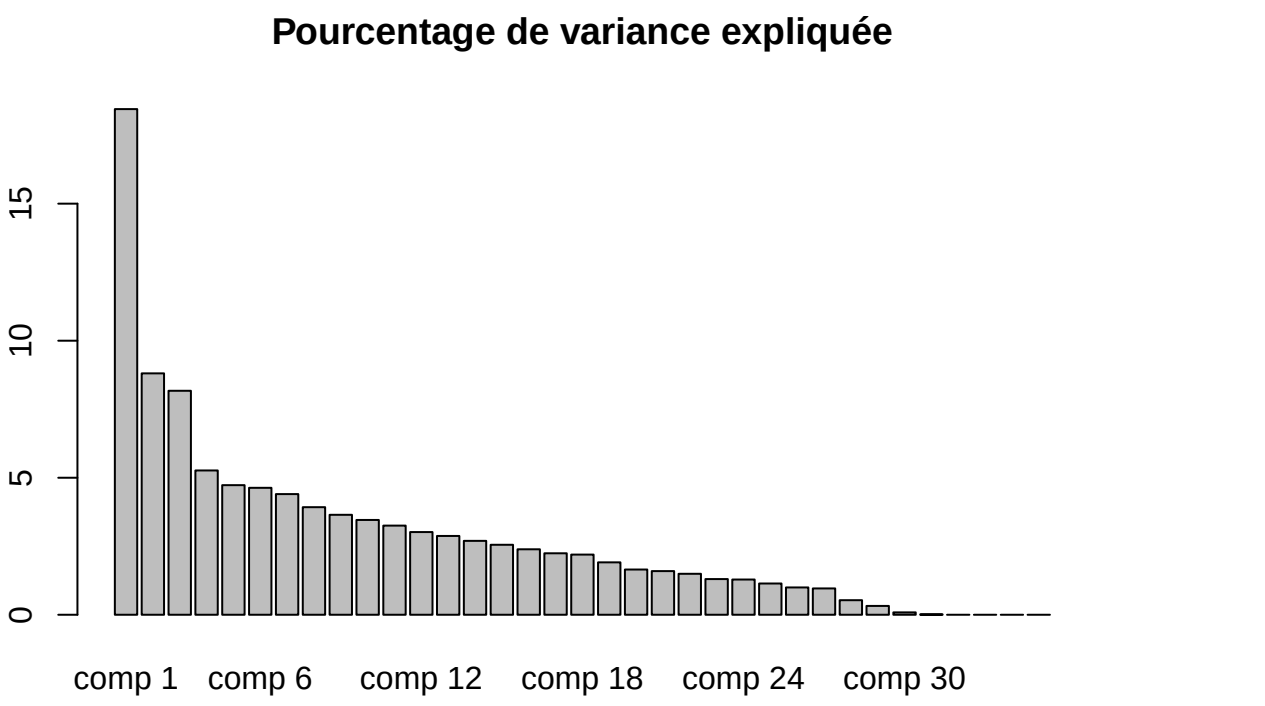


```
plot(res.pca,choix = "var",cex=.5,lim.cos2.var = 0.2,graph.type = 'classic')
```

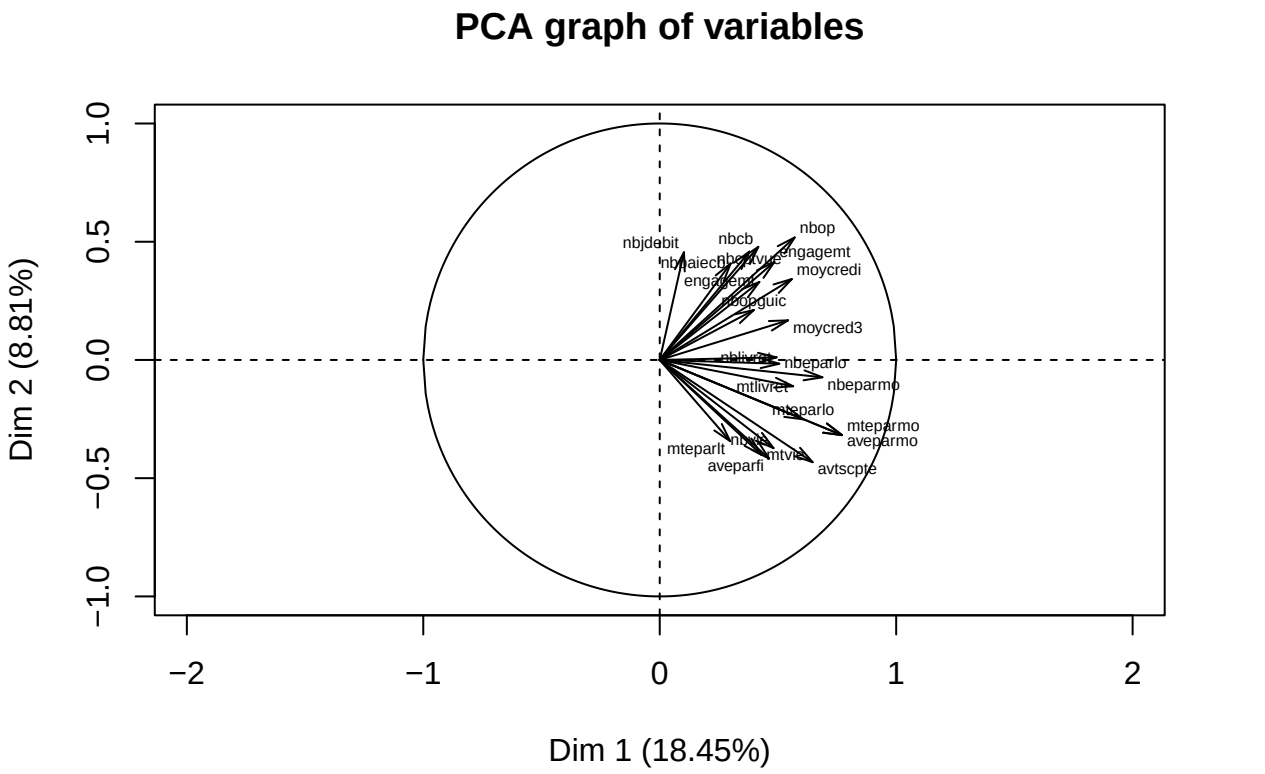


```
plot(res.pca,choix = "ind",label='none',graph.type = 'classic')
```

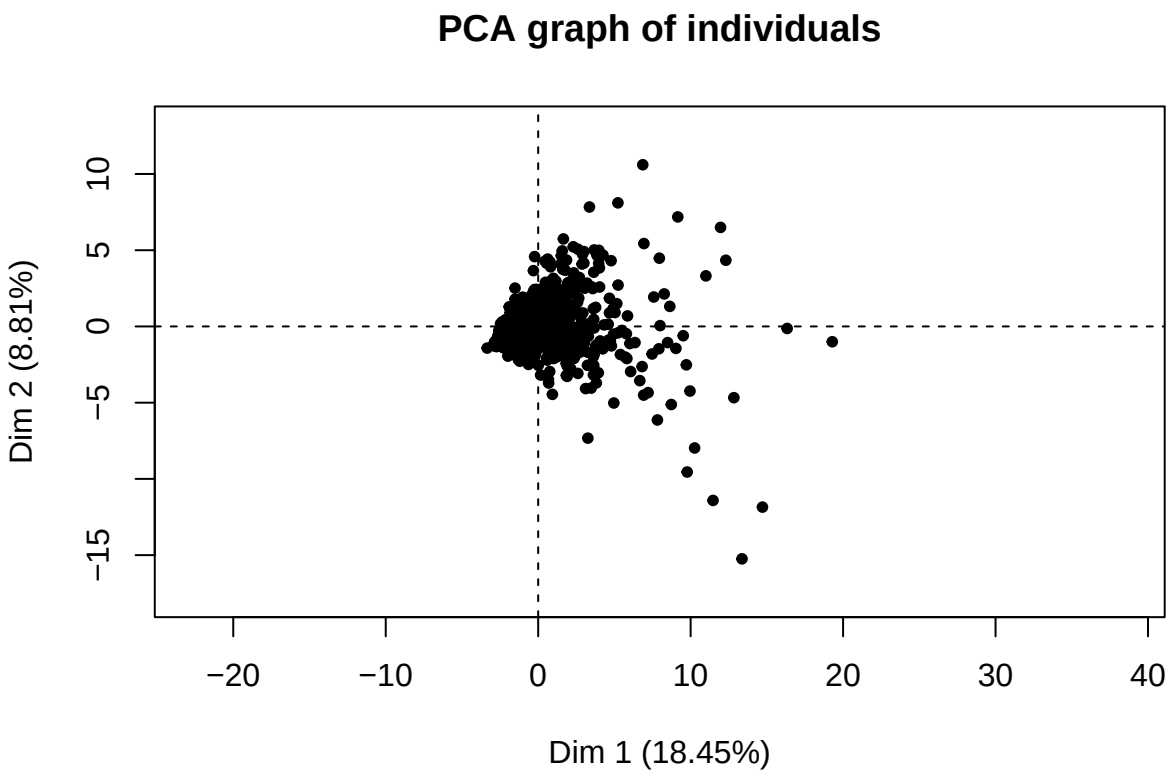

On remarque que le premier axe distingue les clients plutôts riches (à droite) des clients qui le sont moins (à gauche). Le second axe oppose les épargnants (en bas) aux dépensiers (en haut).

Finalement, on peut représenter sur ce graphique quels sont les individus qui possèdent la carte Visa Premier :

```
plot(res.pca,choix = "ind",label='none',graph.type = 'classic',col.ind = (data_categ$cartevp=="Coui")+1
```

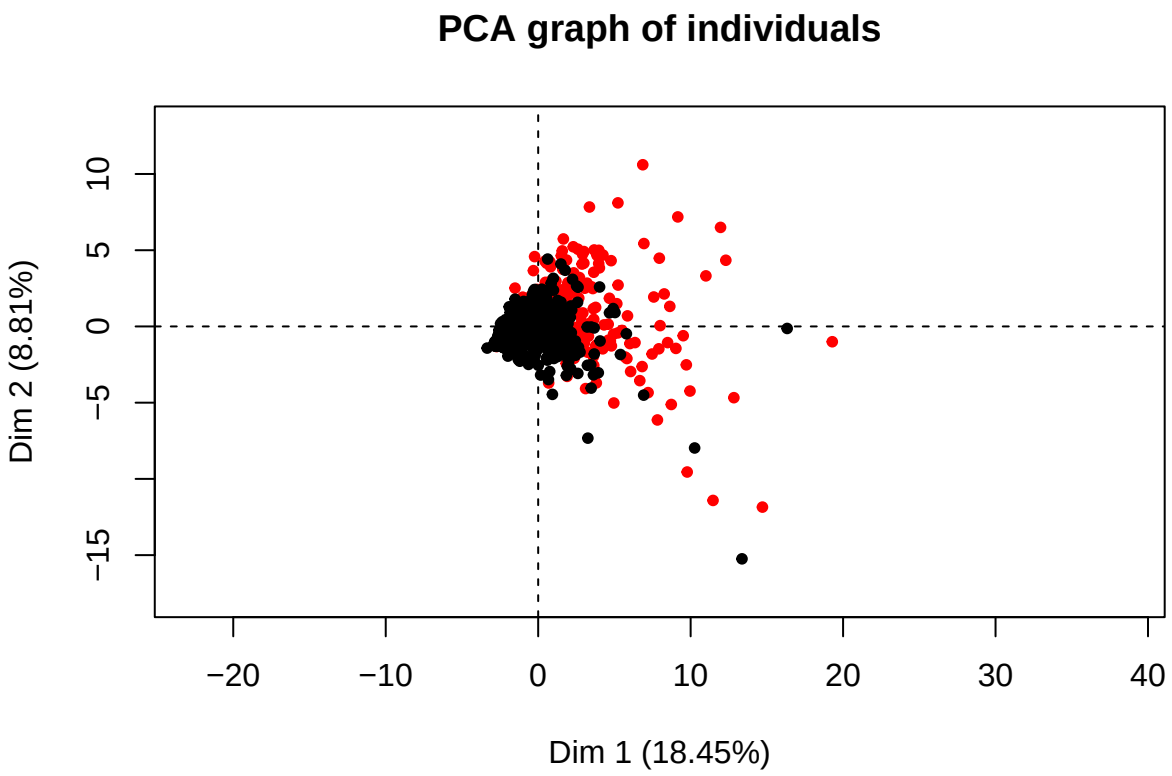

On constate que ce sont les clients riches, et plutôt dépensiers. De plus, la distinction est assez nette entre ceux qui possédent ou non la carte, les modèles de classification que l'on va mettre en oeuvre devrait être plutôt performants.

Prédiction de l'appétence à la carte VP

Afin d'avoir une idée de la difficulté de la tâche, nous pouvons représenter les individus dans le plan de l'ACP en les différenciant (avec leur couleur) suivant s'ils possédent ou non la carte VP

```
plot(res.pca,choix = "ind",label='none',col.ind = (data_categ$cartevp=="Coui")+1,graph.type = 'classic'
```

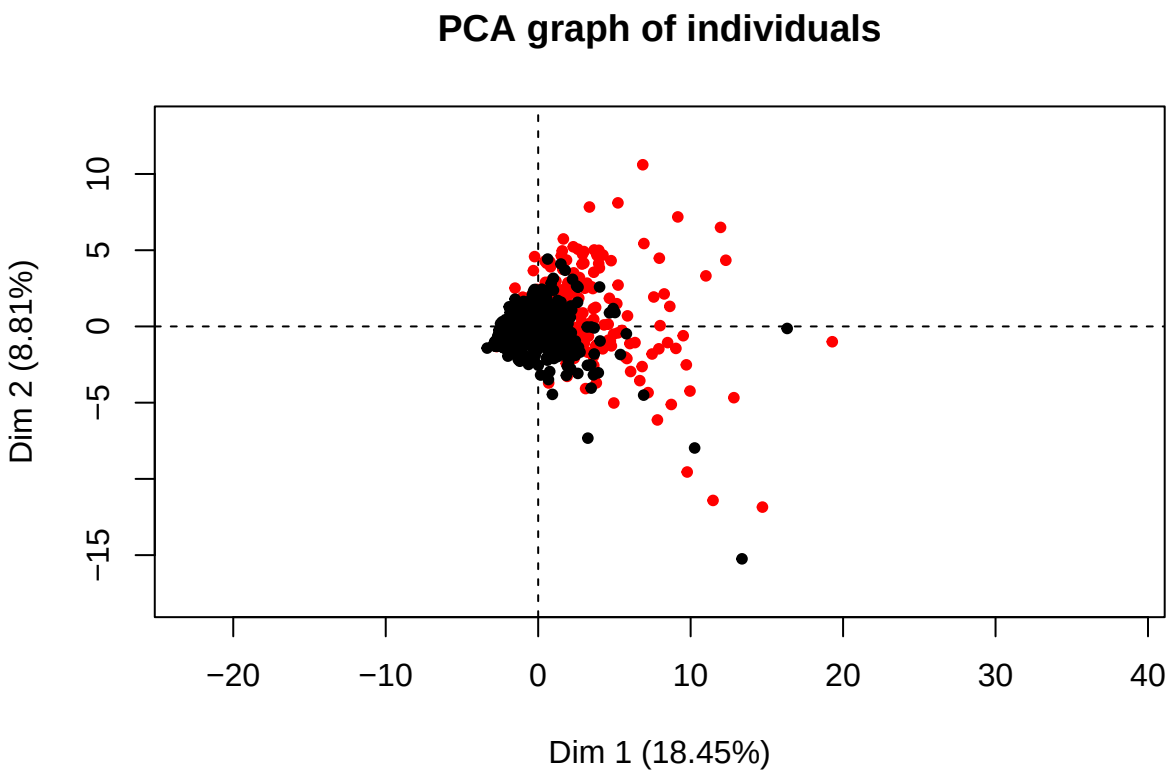

Commençons par construire une base de test, en tirant 300 individus au hasard. Je fixe la graine de mon ordinateur à 1 pour que tout le monde ait le même échantillon de test

```
set.seed(1)
ind_test=sample(1:nrow(data_continuous),300)
dco_test=data_continuous[ind_test,]
dco_app=data_continuous[-ind_test,]
dca_test=data_categ[ind_test,]
dca_app=data_categ[-ind_test,]
```

k-plus proches voisins sur variables quantitatives

Pour choisir k, on va utiliser la validation croisée qui est implémentée en interne dans la fonction knn.cv

```
library(class)
tbc=NULL
for (k in 1:40){
  tmp=knn.cv(dco_app,dca_app$cartevp,k=k)
  tbc=c(tbc,mean(tmp==dca_app$cartevp))
}
plot(tbc,type='l')
```

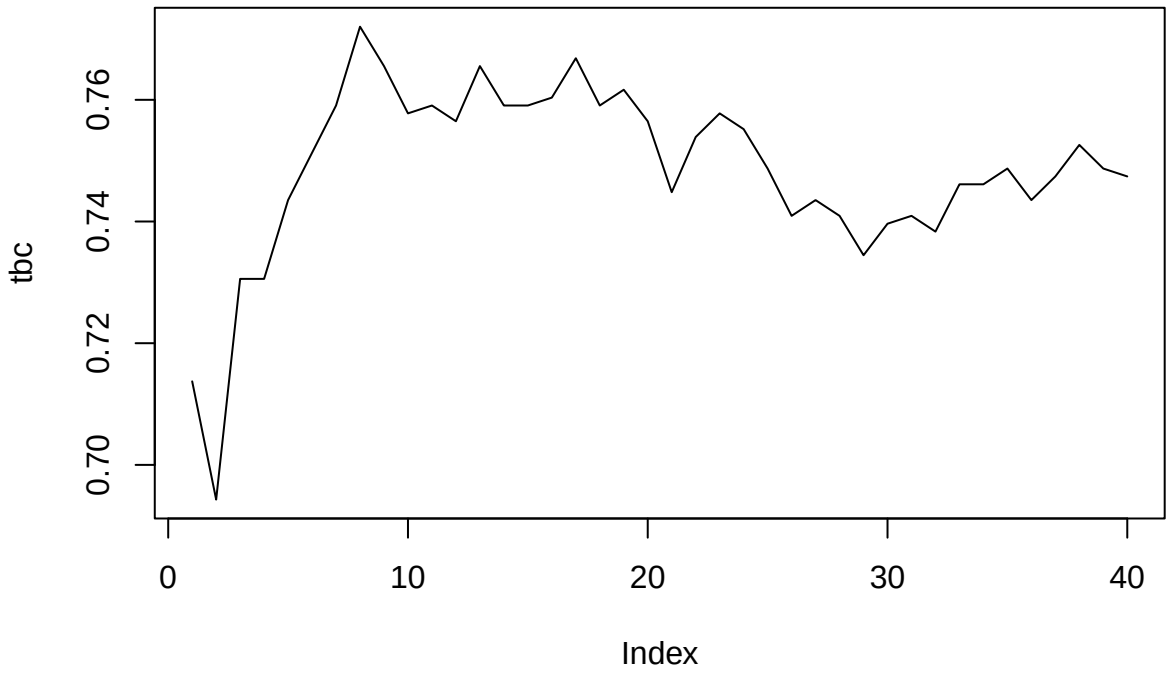

Puis on relance les knn avec la valeur qui maximise le taux de bon classement.

```
print(which.max(tbc))
```

```
## [1] 8
```

```
mod1=knn(dco_app,dco_test,dca_app$cartevp,k=which.max(tbc))
```

Et on évalue le taux de bon classement sur l'échantillon test :

```
mean(mod1==dca_test$cartevp)
```

```
## [1] 0.77
```

Arbre (CART) sur variables quantitative

Utilisons un arbre binaire sur les données quantitatives. Pour cela il faut utiliser un dataframe et donc rapatrier la variable à prédire cartevp dans le même dataframe que les variables quanti

```
library('rpart');library('rpart.plot')
dfco_app=data.frame(dco_app,cartevp=as.factor(dca_app$cartevp))
mod2=rpart(cartevp~.,data=dfco_app)
p=predict(mod2,newdata = dco_test,type='class')
rpart.plot(mod2)
```

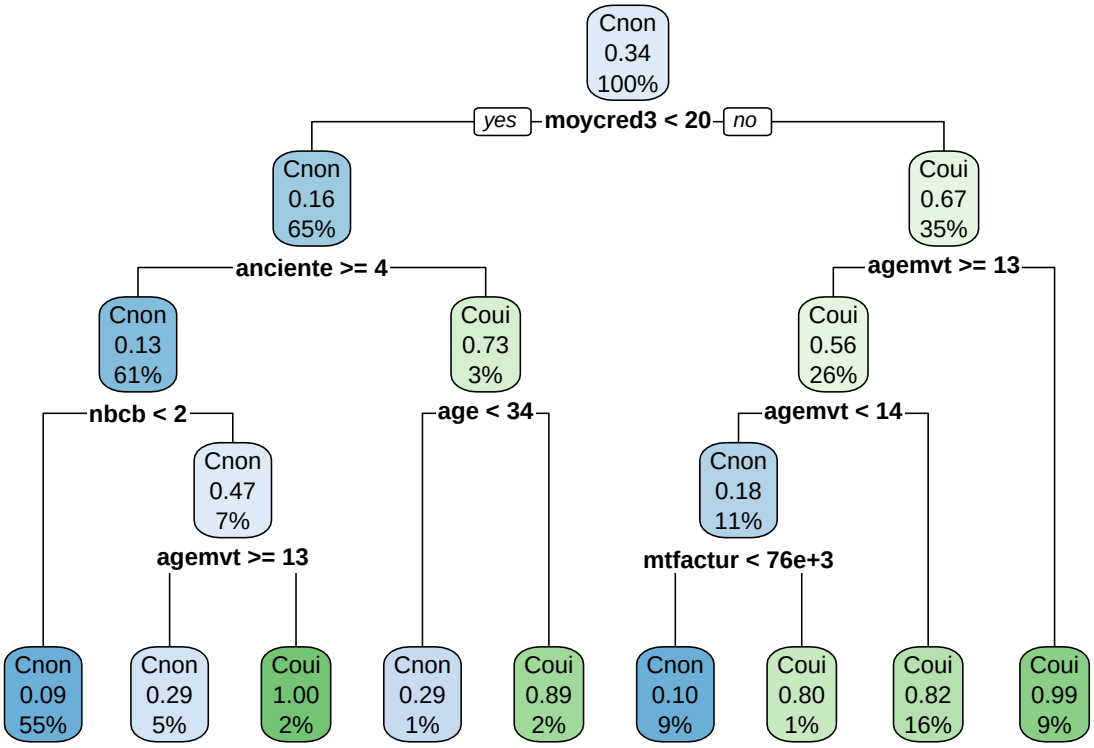

Taux de bon classement par Arbre de classification sur les variables quanti :

```
mean(p==dca_test$cartevp)
```

```
## [1] 0.8933333
```

Arbre (CART) sur variables quantitative + catégorielle

Utilisons un arbre binaire sur les données quantitatives. Pour cela il faut utiliser un dataframe et donc rapatrier la variable à prédire cartevp dans le même dataframe que les variables quanti

```
library('rpart');library('rpart.plot')
df_app=data.frame(dco_app,dca_app)
df_test=data.frame(dco_test,dca_test)
mod3=rpart(cartevp~.,data=df_app)
p=predict(mod3,newdata = df_test,type='class')
rpart.plot(mod3)
```

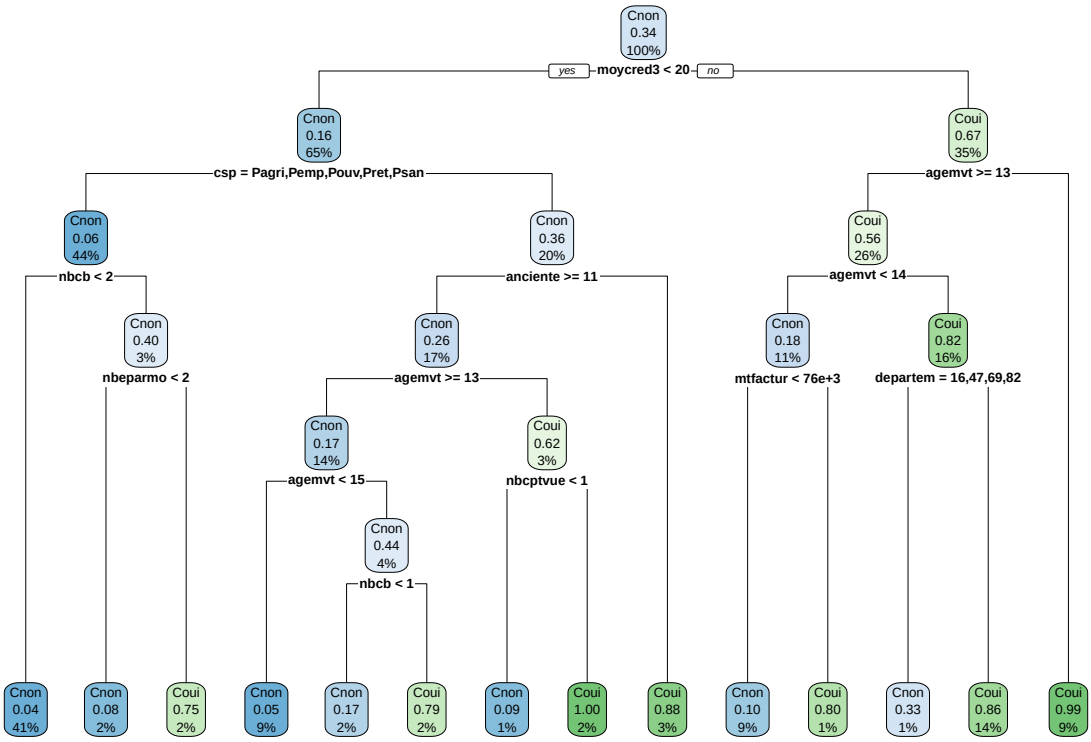


```
mean(p==dca_test$cartevp)
```

```
## [1] 0.8866667
```

Forêt aléatoire sur les variables quantitatives

Utilisons une forêt aléatoire, en laissant les paramètres (ntree :nombre d'arbre et mtry : nombre de variables candidates à chaque coupure) par défaut

```
library(randomForest)
```

```
## Warning: package 'randomForest' was built under R version 4.4.1
```

```
## randomForest 4.7-1.2
```

```
## Type rfNews() to see new features/changes/bug fixes.
```

```
mod4=randomForest(cartevp~.,data=dfco_app)
p=predict(mod4,newdata = dco_test,type='class')
```

Le taux d'erreur est

```
mean(p==dca_test$cartevp)
```

```
## [1] 0.9233333
```

On peut regarder l'importance des variables :

```
varImpPlot(mod4)
```

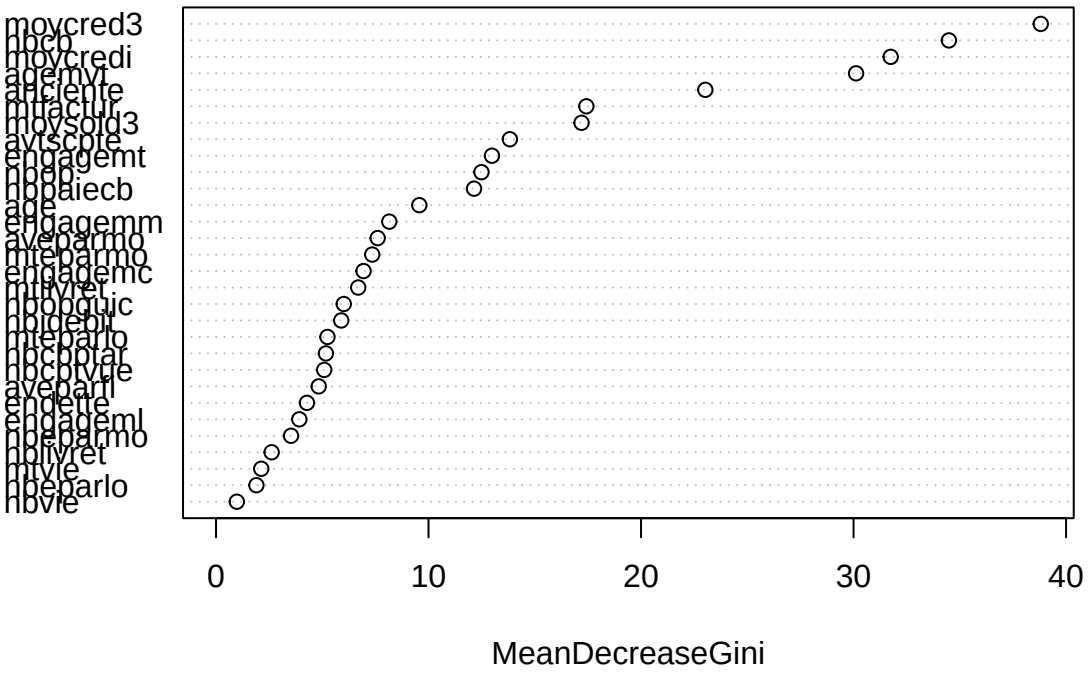

Régression logistique

Effectuons une régression logistique sur les variables continues. Ajouter les variables catégorielles ne va pas forcément beaucoup aidé (au vu des résultats précédents), et va poser des soucis d'estimation du fait du grand nombre de département notamment (et du peu d'observation pour certains départements)

```
mod5=glm(cartevp~.,data=dfco_app,family=binomial(link = "logit"))
summary(mod5)
```

```
##
## Call:
## glm(formula = cartevp ~ ., family = binomial(link = "logit"),
##     data = dfco_app)
##
## Coefficients: (4 not defined because of singularities)
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept) -4.107e+00  6.402e-01  -6.416 1.40e-10 ***
## age          1.785e-02  1.127e-02   1.583 0.113358
## anciente    -2.033e-03  9.126e-04  -2.228 0.025913 *
## mtrejet      8.605e-02  7.183e-02   1.198 0.230914
## nbopguic     2.593e-01  7.326e-02   3.539 0.000401 ***
## moycred3    -1.328e-03  3.620e-03  -0.367 0.713800
## aveparmo     7.971e-06  6.947e-06   1.147 0.251204
## endette     -1.871e-02  1.069e-02  -1.750 0.080129 .
## engagemt     1.373e-06  7.547e-07   1.819 0.068961 .
## engagemc     2.838e-05  1.303e-05   2.179 0.029356 *
## engagemm     9.629e-06  2.721e-06   3.539 0.000401 ***
## nbcptvue     4.335e-01  3.409e-01   1.272 0.203512
## moysold3     1.229e-05  5.734e-06   2.143 0.032141 *
## moycredi     2.941e-02  8.213e-03   3.581 0.000343 ***
## agemvt      -6.611e-03  9.728e-03  -0.680 0.496746
```

```
## nbop        -5.216e-02  1.043e-02  -5.000 5.73e-07 ***
## mtfactur     7.954e-06  3.049e-06   2.609 0.009093 **
## engageml            NA         NA      NA       NA
## nbvie        1.737e-03  2.642e-01   0.007 0.994755
## mtvie       -3.802e-06  2.340e-06  -1.625 0.104199
## nbeparmo     2.207e+12  5.856e+13   0.038 0.969935
## mteparmo            NA         NA      NA       NA
## nbeparlo    -2.207e+12  5.856e+13  -0.038 0.969935
## mteparlo     2.470e-06  6.595e-06   0.375 0.708026
## nblivret    -2.207e+12  5.856e+13  -0.038 0.969935
## mtlivret     4.099e-06  6.651e-06   0.616 0.537655
## nbeparlt    -2.207e+12  5.856e+13  -0.038 0.969935
## mteparlt            NA         NA      NA       NA
## nbeparte    -2.207e+12  5.856e+13  -0.038 0.969935
## mteparte            NA         NA      NA       NA
## nbpaiecb     1.595e-02  1.704e-02   0.936 0.349200
## nbcb         2.539e+00  2.507e-01  10.127  < 2e-16 ***
## nbcbptar    -3.120e+00  5.115e-01  -6.099 1.07e-09 ***
## avtscpte    -9.180e-06  3.393e-06  -2.706 0.006816 **
## aveparfi     1.208e-05  4.285e-06   2.819 0.004812 **
## nbjdebit     4.309e-03  5.590e-03   0.771 0.440861
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 990.45  on 771  degrees of freedom
## Residual deviance: 518.77  on 740  degrees of freedom
## AIC: 582.77
##
## Number of Fisher Scoring iterations: 25
```

L'effet de certaines variables ne peut être estimé (ce sont les variables quasiment constante, où seuls quelques individus ont des valeurs non nuls). Une sélection de variable stepwise devrait solutionner cela

```
library(MASS)
mod5_2=step(mod5,direction = "both",trace = F)
summary(mod5_2)
```

```
##
## Call:
## glm(formula = cartevp ~ age + anciente + mtrejet + nbopguic +
##     moycred3 + aveparmo + endette + engagemt + engagemc + engagemm +
##     nbcptvue + moysold3 + moycredi + agemvt + nbop + mtfactur +
##     mtvie + nbeparmo + nbeparlo + mteparlo + nblivret + mtlivret +
##     nbeparlt + nbeparte + nbpaiecb + nbcb + nbcbptar + avtscpte +
##     aveparfi, family = binomial(link = "logit"), data = dfco_app)
##
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept) -4.168e+00  6.325e-01  -6.591 4.38e-11 ***
## age          1.723e-02  1.105e-02   1.559 0.119066
## anciente    -2.150e-03  9.122e-04  -2.357 0.018399 *
## mtrejet      8.668e-02  6.865e-02   1.263 0.206721
## nbopguic     2.527e-01  7.221e-02   3.500 0.000465 ***
```

```
## moycred3    -1.187e-03  3.430e-03  -0.346 0.729338
## aveparmo     7.968e-06  6.939e-06   1.148 0.250859
## endette     -1.617e-02  1.059e-02  -1.527 0.126700
## engagemt     1.340e-06  7.476e-07   1.792 0.073099 .
## engagemc     3.017e-05  1.279e-05   2.359 0.018315 *
## engagemm     9.895e-06  2.723e-06   3.634 0.000279 ***
## nbcptvue     4.499e-01  3.373e-01   1.334 0.182259
## moysold3     1.203e-05  5.617e-06   2.142 0.032185 *
## moycredi     2.916e-02  8.085e-03   3.606 0.000311 ***
## agemvt      -6.526e-03  9.397e-03  -0.694 0.487396
## nbop        -5.164e-02  1.028e-02  -5.023 5.10e-07 ***
## mtfactur     8.059e-06  3.035e-06   2.655 0.007935 **
## mtvie       -3.859e-06  2.340e-06  -1.649 0.099146 .
## nbeparmo     4.977e+13  5.599e+13   0.889 0.374032
## nbeparlo    -4.977e+13  5.599e+13  -0.889 0.374032
## mteparlo     2.599e-06  6.613e-06   0.393 0.694327
## nblivret    -4.977e+13  5.599e+13  -0.889 0.374032
## mtlivret     4.078e-06  6.675e-06   0.611 0.541284
## nbeparlt    -4.977e+13  5.599e+13  -0.889 0.374032
## nbeparte    -4.977e+13  5.599e+13  -0.889 0.374032
## nbpaiecb     1.689e-02  1.684e-02   1.003 0.315846
## nbcb         2.531e+00  2.483e-01  10.194  < 2e-16 ***
## nbcbptar    -3.097e+00  5.057e-01  -6.124 9.13e-10 ***
## avtscpte    -9.273e-06  3.389e-06  -2.736 0.006220 **
## aveparfi     1.225e-05  4.280e-06   2.861 0.004224 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 990.45  on 771  degrees of freedom
## Residual deviance: 520.24  on 742  degrees of freedom
## AIC: 580.24
##
## Number of Fisher Scoring iterations: 25
```

Beaucoup de variables restent non significatives...

Effectuons une pénalisations LASSO

```
require(doMC)
```

```
## Loading required package: doMC
```

```
## Loading required package: foreach
```

```
## Loading required package: iterators
```

```
## Loading required package: parallel
```

```
registerDoMC(cores=2)
library(glmnet)
```

```
## Loading required package: Matrix
```

```
## Loaded glmnet 4.1-8
```

```
fit=cv.glmnet(as.matrix(dco_app),dca_app$cartevp,alpha=1,family="binomial",parallel=TRUE)
p=predict(fit, newx = as.matrix(dco_test),s="lambda.min",type ="class")
```

```r
print(mean(p==dca_test$cartevp))
```

```
## [1] 0.84
```

Estimons maintenant une régression logistique sur les variables sélectionnées par la régression LASSO

```r
mod6=glmnet(as.matrix(dco_app),dca_app$cartevp,alpha=1,family="binomial",lambda = fit$lambda.1se)
varindex=which((abs(mod6$beta)>0))
mod7=glm(cartevp~.,data=dfco_app[,c(varindex,ncol(dfco_app))],family=binomial(link = "logit"))
summary(mod7)
```

```
##
## Call:
## glm(formula = cartevp ~ ., family = binomial(link = "logit"),
##     data = dfco_app[, c(varindex, ncol(dfco_app))])
##
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept) -3.421e+00  2.493e-01 -13.718  < 2e-16 ***
## nbopguic     1.316e-01  4.492e-02   2.930  0.00339 **
## moycred3     1.603e-03  2.743e-03   0.584  0.55891
## engagemt     8.117e-07  5.476e-07   1.482  0.13826
## engagemc     2.005e-05  9.673e-06   2.073  0.03816 *
## engagemm     6.379e-06  2.327e-06   2.742  0.00611 **
## moycredi     8.834e-03  4.893e-03   1.805  0.07101 .
## nbcb         1.984e+00  1.858e-01  10.681  < 2e-16 ***
## nbcbptar    -2.798e+00  4.486e-01  -6.238 4.44e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 990.45  on 771  degrees of freedom
## Residual deviance: 600.95  on 763  degrees of freedom
## AIC: 618.95
##
## Number of Fisher Scoring iterations: 6
```

```r
p=predict(mod7,newdata = dco_test[,varindex],type = "response")
y_predit=rep("Cnon",length(p));y_predit[p>.5]="Coui"
print(mean(y_predit==dca_test$cartevp))
```

```
## [1] 0.82
```